

Random-Forest-Modell – Methodik

Unsere Prognose schätzt für jedes mögliche WM-Spiel, wie viele Tore beide Mannschaften erzielen werden und leitet daraus ab, wie wahrscheinlich ein Sieg, ein Unentschieden oder eine Niederlage ist. Wir schauen dabei nicht nur auf bisherige Ergebnisse, sondern auch darauf, wie die Mannschaften gespielt haben: wie viele Chancen sie hatten, wie gefährlich ihre Schüsse waren, wie dominant sie den Ball kontrollierten. Das Modell basiert auf einem Verfahren des maschinellen Lernens namens Random Forest (wörtlich: „Zufallswald“) und lernt aus tausenden vergangenen Länderspielen selbstständig, welche Merkmale einer Mannschaft am besten verraten, wie viele Tore sie im nächsten Spiel erzielen wird.

Schritt 1: Datengrundlage

Grundlage sind alle verfügbaren Länderspiele der A-Nationalmannschaften der Männer mit bekanntem Endstand. Wir berücksichtigen ausschließlich Spiele zwischen zwei FIFA-Mitgliedsverbänden. Begegnungen mit nicht anerkannten Auswahlen wie dem Baskenland fallen damit heraus. Außerdem filtern wir Spiele heraus, bei denen eine A-Nationalmannschaft gegen eine Nachwuchsauswahl antritt, da solche Ergebnisse wenig über die tatsächliche Stärke einer Mannschaft aussagen. Die Daten stammen von Sofascore und wurden automatisiert ausgelesen (sogenanntes Web Scraping).

Dabei schauen wir nicht nur auf das Endergebnis, sondern auch auf 33 detaillierte Statistiken pro Spiel und Mannschaft: Schüsse aufs Tor, Ballbesitz, erwartete Tore (xG), Eckbälle, gewonnene Zweikämpfe, Passquoten, Großchancen und vieles mehr. Der Grund: Das nackte Ergebnis erzählt nur einen Teil der Geschichte. Eine Mannschaft, die ein Spiel klar dominiert, sich viele Großchancen erarbeitet und am Ende trotzdem unglücklich 0:1 verliert, ist in Wahrheit stärker, als es das Ergebnis vermuten lässt. Diese Spielstatistiken machen solche Unterschiede sichtbar.

(xG, „expected goals“, schätzt für jeden Torschuss, wie wahrscheinlich er zu einem Tor führt und misst so, wie gefährlich eine Mannschaft wirklich war, unabhängig vom Glück im Abschluss.)

Schritt 2: Die Form einer Mannschaft

Ein einzelnes Spiel ist wenig aussagekräftig, denn jede Mannschaft hat gute und schlechte Tage. Uns interessiert die aktuelle Stärke einer Mannschaft, also ihre Form. Deshalb fassen wir für jede Mannschaft die jeweils letzten 15 Spiele zusammen und bilden Durchschnittswerte: durchschnittlich erzielte Tore, durchschnittlicher Ballbesitz, durchschnittliche xG und so weiter für alle Statistiken aus Schritt 1.

Zusätzlich geben wir der Mannschaft zwei bewährte Stärkemaße mit: ihre Elo-Zahl (eine etablierte Wertungszahl, die die gesamte Spielhistorie in einer einzigen Zahl zusammenfasst; je höher, desto stärker) und den durchschnittlichen Marktwert des Kaders (als Maß für die individuelle Qualität der Spieler). Da wir die 33 Spielstatistiken plus xG-Werte und weitere Formkennzahlen wie Siegwahrscheinlichkeit und Tordifferenz für *beide* Teams separat berechnen und

zusätzlich Elo und Marktwert beider Teams hinzunehmen, beschreiben am Ende 94 solcher Zahlen jede Begegnung.

Schritt 3: Wie der Random Forest lernt

3.1: Ein einzelner Entscheidungsbaum

Stellen wir uns zunächst einen einzelnen „Entscheidungsbaum“ vor. Das ist im Grunde eine lange Kette von Ja/Nein-Fragen, ganz ähnlich einem Frage-Antwort-Spiel. Für eine Begegnung fragt der Baum zum Beispiel: „Ist die Elo-Zahl der einen Mannschaft mehr als 50 Punkte höher als die der anderen?“ Lautet die Antwort Ja, stellt er eine nächste Frage, etwa: „Lag der xG-Schnitt des Gegners zuletzt unter 1,2?“, und so weiter.

Nach mehreren solcher Fragen landet die Begegnung schließlich in einem Endpunkt. Dort hat der Baum während des Lernens notiert, wie viele Tore Mannschaften in genau dieser Situation im Schnitt erzielt haben: etwa „2,1 Tore“. Diese Zahl ist seine Schätzung. Die Fragen und Schwellenwerte denkt sich der Baum nicht aus; er lernt sie selbstständig aus den historischen Spielen, indem er jene Fragen sucht, die die Tore am besten erklären.

3.2: Vom Baum zum Wald

Ein einzelner Baum ist allerdings launisch: Je nachdem, welche Spiele er zufällig zu sehen bekommt, fällt er etwas anders aus, und er neigt dazu, sich zu sehr an Zufälligkeiten der Vergangenheit zu klammern. Die Lösung: statt einem Baum bauen wir 500.

Damit die Bäume nicht alle gleich aussehen, bekommt jeder von ihnen eine zufällige (daher der Name „Random Forest“) Auswahl der Spiele zum Lernen und darf bei jeder Frage nur aus einer zufälligen Teilmenge der Merkmale wählen. So entstehen 500 leicht unterschiedliche Bäume, die jeweils andere Aspekte betonen. Für eine Vorhersage befragen wir alle 500 und bilden den Durchschnitt ihrer Schätzungen. Dieses Mitteln ist der entscheidende Trick: Die Ausreißer einzelner Bäume gleichen sich gegenseitig aus, und übrig bleibt eine stabile, verlässliche Schätzung.

3.3: Zwei Wälder für zwei Mannschaften

Ein Spiel hat zwei Tor-Zahlen: eine pro Mannschaft. Deshalb bauen wir zwei solcher Wälder: einer schätzt die Tore der einen, der andere die Tore der anderen Mannschaft. Für jede Paarung erhalten wir so zwei erwartete Tor-Zahlen, zum Beispiel 1,9 Tore für Deutschland und 0,8 für den Gegner.

Beide Wälder erhalten dabei denselben vollständigen Datensatz, also die Statistiken und Stärkemaße beider Mannschaften. Der Tor-Wald hat damit genauso viel Wissen über den Gegner wie der Gegentore-Wald über die eigene Mannschaft.

3.4: Von Toren zu Ergebnis-Wahrscheinlichkeiten

Die zwei erwarteten Tor-Zahlen sind noch keine fertige Prognose, denn sie sagen ja nur, wie viele Tore im Schnitt fallen. Im echten Spiel kann es immer mehr oder weniger werden: ein

Spiel endet schließlich immer mit ganzen Torzahlen. Diese Schwankung beschreibt die sogenannte Poisson-Verteilung, ein Standardmodell für seltene Ereignisse wie Tore: Aus einer erwarteten Tor-Zahl berechnet sie, wie wahrscheinlich genau 0, 1, 2, 3 ... Tore sind.

Kombinieren wir das für beide Mannschaften, erhalten wir für jeden denkbaren Endstand (0:0, 1:0, 2:1 ...) eine Wahrscheinlichkeit. Diese Tabelle beschreibt eine Begegnung vollständig: Zählt man die passenden Felder zusammen, ergeben sich daraus Sieg-, Unentschieden- und Niederlagewahrscheinlichkeit.

3.5: Heimvorteil für die Gastgeber

Die Weltmeisterschaft 2026 findet in den USA, Kanada und Mexiko statt. Für diese drei Mannschaften berücksichtigen wir einen Heimvorteil, allerdings nur in den Spielen, die tatsächlich in ihrem eigenen Land stattfinden. Dafür haben wir den offiziellen Spielplan ausgewertet und für jedes Spiel festgehalten, in welchem der drei Gastgeberländer es ausgetragen wird.

Technisch setzen wir den Heimvorteil über die Elo-Zahl um: Spielt eine Gastgebernation im eigenen Land, erhält sie beim Berechnen der erwarteten Tore einen Bonus von 100 Elo-Punkten. Das entspricht dem in der Literatur etablierten Heimvorteileffekt (eloratings.net). Für alle anderen Mannschaften und alle anderen Spiele wird neutral simuliert.

Schritt 4: Turniersimulation

4.1: Gruppenphase

Die 48 Mannschaften sind in 12 Gruppen zu je 4 Mannschaften eingeteilt. Jede Mannschaft spielt gegen die drei anderen ihrer Gruppe, das ergibt 6 Spiele pro Gruppe und insgesamt 72 Gruppenspiele. Für jedes Spiel wird aus der zugehörigen Ergebnis-Matrix ein konkreter Endstand zufällig gezogen — entsprechend den dort hinterlegten Wahrscheinlichkeiten. Es gibt drei Punkte für einen Sieg, einen Punkt für ein Unentschieden und keinen Punkt für eine Niederlage.

4.2: Gruppentabelle aufstellen

Nach den sechs Spielen einer Gruppe wird die Tabelle gebildet. Bei Punktgleichheit entscheidet zuerst die Tordifferenz, dann die Zahl der erzielten Tore; bleibt es danach gleich, entscheidet bei uns eine Zufallsauswahl, da wir beispielsweise Gelbe Karten nicht simulieren. Pro Gruppe qualifizieren sich der Erste und der Zweite direkt für die K.O.-Runde.

4.3: Die acht besten Gruppendritten ermitteln

Insgesamt ziehen 32 Mannschaften ins Sechzehntelfinale ein. Neben den 24 direkt Qualifizierten werden also noch 8 weitere Mannschaften benötigt. Diese gehen an die 8 besten Drittplatzierten aller 12 Gruppen. Verglichen werden zuerst die Punkte, dann die Tordifferenz, dann die erzielten Tore.

4.4: K.O.-Runde durchspielen

Ab dem Sechzehntelfinale geht es im Ausscheidungsmodus weiter: Sechzehntelfinale, Achtelfinale, Viertelfinale, Halbfinale und Finale. Jedes K.O.-Spiel wird wie ein Gruppenspiel aus der Ergebnis-Matrix gezogen. Endet ein Spiel unentschieden, muss eine Entscheidung fallen: Das Elfmeterschießen wird abgeschwächt anhand der Spielstärke entschieden.

Aus der Ergebnis-Matrix wird die Sieg-Wahrscheinlichkeit p der einen Mannschaft (ohne Unentschieden) bestimmt; die Wahrscheinlichkeit, dass sie das Elfmeterschießen gewinnt, ist dann $p_{\text{Elfmeter}} = 0,5 + (p - 0,5) / 2$. Bei gleich starken Mannschaften bleibt es damit bei 50:50, bei einem klaren Favoriten steigt seine Wahrscheinlichkeit auf höchstens 75 Prozent.

Schritt 5: Monte Carlo Simulation

Ein einzelnes durchgespieltes Turnier ist nur eine Zufallsziehung von unendlich vielen. Eine belastbare Aussage entsteht erst durch viele Wiederholungen. Wir simulieren das gesamte Turnier daher 100.000-mal. Für jede Mannschaft zählen wir, in wie vielen dieser Turniere sie eine bestimmte Runde erreicht. Der Anteil der Turniere, in denen eine Mannschaft eine Runde erreicht, ist ihre geschätzte Wahrscheinlichkeit für diese Runde.

Schritt 6: Prognose anzeigen

Am Ende erhalten wir für jede der 48 Mannschaften die Wahrscheinlichkeit, Gruppensieger zu werden, das Sechzehntelfinale, Achtelfinale, Viertelfinale, Halbfinale und Finale zu erreichen sowie Weltmeister zu werden. Diese Wahrscheinlichkeiten bilden unsere offizielle Prognose.

Worin sich Prognose und Simulation unterscheiden

Die interaktive Simulation arbeitet mit der Elo-Zahl und lässt Sie zahlreiche Parameter selbst einstellen. Die Simulation ist zum Ausprobieren und Verstehen gedacht. Unsere Prognose arbeitet mit dem Random-Forest Modell, schätzt Tore und Gegentore jeder Mannschaft direkt aus einer Vielzahl historischer Statistiken und weiterer Daten wie Marktwerten deren Wichtigkeit im Modell ermittelt wird und kennt keine einstellbaren Regler. Sie ist auf eine möglichst belastbare Vorhersage ausgelegt.

Hinweis zur Interpretation

Auch eine sorgfältig geschätzte Prognose bleibt eine Wahrscheinlichkeitsaussage und keine Vorhersage des tatsächlichen Verlaufs. Dass eine Mannschaft als Favorit gilt, bedeutet nicht, dass sie gewinnen wird. Fußball lebt gerade von den Überraschungen, die das Modell als seltene, aber durchaus mögliche Welten mit abbildet. Das Modell kennt zudem nur, was in den Ergebnissen vergangener Spiele steckt: Verletzungen, Kaderveränderungen, Tagesform oder Trainerwechsel kann es nur insoweit berücksichtigen, wie sie sich bereits in jüngeren Resultaten niedergeschlagen haben.